


지수 산출 파이프라인 · 전체 구조

필터링은 대기환경과 무관한 기사를 제거하는 단계 · 방식을 달리해 관심도 3안 · 요구도 4안을 산출



관심도 지수 · 산출 3안

요구도 선별 없이, 필터링을 통과한 **뉴스 기사수가 곧 지수**



요구도 지수 · 산출 4안

필터링 방식 2종 × 요구도 기사 선별 방식 2종의 조합

공통 원천 · 전체기사수 약 67만건 → 언론 필터링(17개사) 약 21만건

요구도 기사 선별 방식

LLM 요구도 기사 선별 (지수화)

키워드 요구도 기사 선별 (지수화)

키워드 기반 필터링

키워드로 대기환경
무관 기사 제거

요구도 지수 1

키워드 필터링 → LLM 요구선별 (지수화)
혼합 방식

요구도 지수 2

키워드 필터링 → 키워드 요구선별 (지수화)
키워드 단일 방식

LLM 기반 필터링

LLM으로 대기환경
무관 기사 제거

요구도 지수 3 : 현재

LLM 필터링(13만건) → LLM 요구선별 (지수화)
LLM 단일 방식

요구도 지수 4 : 현재2

LLM 필터링(13만건) → 키워드 요구선별 (지수화)
혼합 방식

정리가 필요한 부분

지수 확정 전에 합의가 필요한 항목

01

기사 제외 기준 통일

LLM, 키워드 모두 대기환경과 무관한 기사를 제거하것에 활용중임 (관심도, 요구도 통일 검토)

02

LLM 기반 필터의 관심도 지수화

요구도 지수에 사용하는 LLM 기반 필터 결과를 관심도 지수로도 산출한다 (예정, 관심도 C안).

03

세부 분류 체계와 키워드 확정

대기질 / 대기정책 / 생활(건강)의 분류 체계와 정의를 정해야 한다.
455종을 다 쓰기는 어려우므로 분류에 쓸 키워드도 선별 필요.

04

주제 분류 정의 확정

대기질 / 대기정책 / 생활(건강)의 분류 체계와 각 항목의 정의를 결정해야 한다.

KISDI 데이터 구조

필드	설명	예시 값
dt	기사 시각 (yyyymmddHHMMSS)	20210701205000
href	기사 URL	https://news.naver.com/main/read.nhn?mode=LS2D&mid=shm&sid1=...
title	제목	“아직 정부안 검토 중...8월 전 위원회안 확정하겠다”
content	본문 (플레인 텍스트)	[기후뉴스읽기] 출범 한 달...윤순진 탄소중립위원장 첫 기자회견 “2030년 NDC와 2050 탄소중립 시나리...
sid1_name	대분류	사회
sid2_name	소분류	환경
source	출처	naver

키워드 기반 기사 제외 기준

지수 확정 전에 합의가 필요한 항목